Wetenschappelijke kennis 1.2

College 2: Continue uitkomsten vergelijken tussen twee groepen

Dr Douwe Postmus

Voorjaar 2026

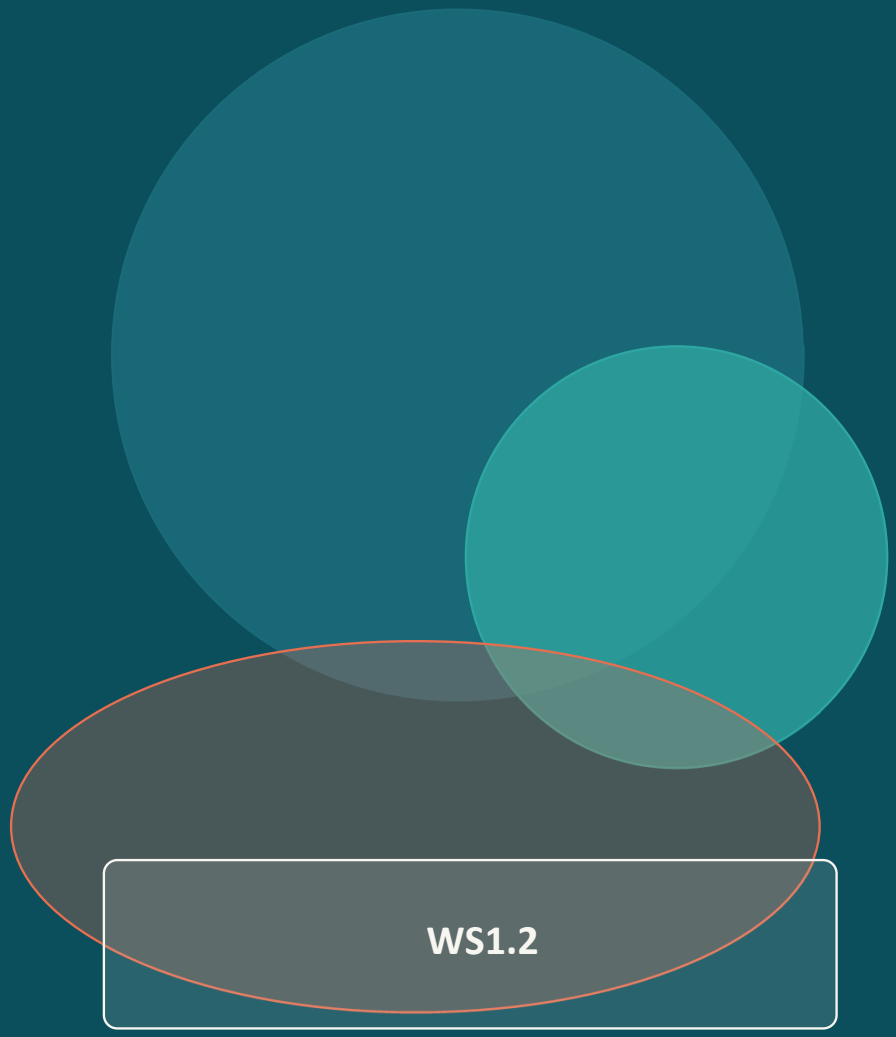

Van één groep naar twee groepen

- In college 1 stond de vraag centraal hoe we met één steekproef een populatieparameter kunnen schatten en toetsen.
- In dit college vergelijken we twee onafhankelijke groepen op een continue uitkomst.
- De centrale inferentiële vraag verschuift daarmee van één populatiegemiddelde naar het verschil tussen twee populatiegemiddelden.

Deel 1

Onafhankelijke t-toets bij twee groepen

Casus 1: BBS% bij recallpatiënten

- Populatie: volwassen recallpatiënten in de mondzorgpraktijk (n = 80).
- Interventie: standaard mondhygiëne-instructie + motiverende gespreksvoering (n = 40).
- Controle: standaard mondhygiëne-instructie zonder motiverende gespreksvoering (n = 40).
- Uitkomst: gemiddeld BBS% bij 3-maands controle.
- Vraag: in hoeverre verschilt het gemiddelde BBS% tussen de interventiegroep en de controlegroep?

BBS = Bloeding Bij Sonderen
BBS% = percentage bloedende sites bij parodontaal sonderen (schaal 0-100)

Beschrijvende statistiek van de steekproef

- We starten met een beschrijving van de twee steekproeven.
- In beide groepen zijn 40 recallpatiënten gemeten.
- Het gemiddelde BBS% ligt lager in de interventiegroep dan in de controlegroep.
- De spreiding lijkt in beide groepen vergelijkbaar.

Geschat gemiddeld verschil in deze steekproef: 26,3 – 30,1 = −3,8 procentpunt.

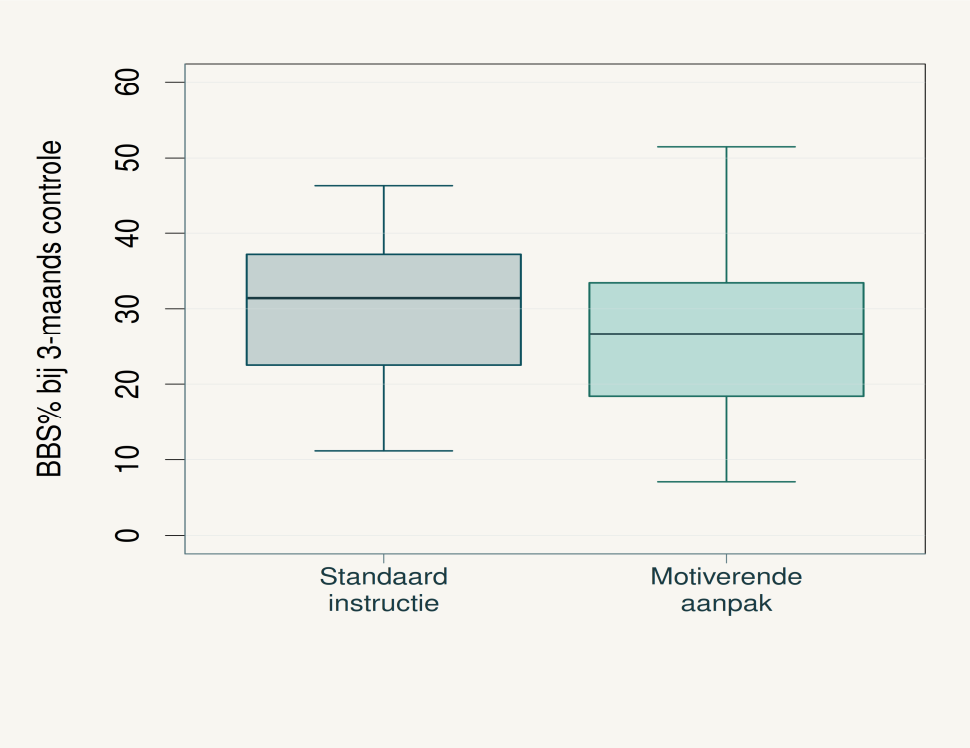

Steekproefsamenvatting

Groep	n	Gem. ($\bar{x}$)	SD (s)
Interventie	40	26,3%	9,7%
Controle	40	30,1%	9,8%

Van populatieparameter naar schatting

- Bij statistische inferentie moeten we drie niveaus uit elkaar houden:
  - de onbekende grootheid in de populatie,
  - de schatter die we op een steekproef toepassen,
  - en de schatting die we in deze steekproef vinden.
- In deze casus gaat het daarbij om het gemiddeld verschil tussen beide groepen.

Populatieparameters zijn onbekend. Schatters zijn toevalsvariabelen vóórdat je de steekproef ziet. Schattingen zijn de geobserveerde waarden in deze steekproef.

Parameter, schatter en schatting

Populatieparameter = onbekende vaste grootheid.
Schatter = regel op de steekproef.
Schatting = de geobserveerde waarde in deze steekproef.

Grootheid wat vergelijk je?	Populatieparameter onbekende vaste grootheid	Schatter regel op de steekproef	Schatting in deze steekproef geobserveerde waarde
Gemiddelde interventiegroep	μ_I	$\bar{X}_I$	$\bar{x}_I = 26{,}3$
Gemiddelde controlegroep	μ_C	$\bar{X}_C$	$\bar{x}_C = 30{,}1$
Gemiddeld verschil	$\mu_I - \mu_C$	$\bar{X}_I - \bar{X}_C$	$\bar{x}_I - \bar{x}_C = -3{,}8$

σ hoort bij de populatie, s hoort bij de steekproef.

Populatiespreiding (σ)
σ_I, σ_C

Steekproefspreiding (s)
$s_I = 9{,}7$ en $s_C = 9{,}8$

De standaardfout van een schatting

- Een schatting is nooit exact hetzelfde in elke steekproef.
- De standaardfout beschrijft hoeveel die schatting kan variëren van steekproef tot steekproef.
- In college 1 bespraken we hoe de standaardfout wordt berekend voor één steekproefgemiddelde.
- In deze casus hebben we de standaardfout nodig van het geschatte gemiddeld verschil tussen twee groepen.

Van populatiegemiddelde naar gemiddeld verschil

College 1	schatter: $\bar{x}$ geschatte SE: $s / \sqrt{n}$
College 2	schatter: $\bar{x}_I - \bar{x}_C$ geschatte SE: $s_p \sqrt{(1/n_I + 1/n_C)}$

Berekening van de geschatte standaardfout

- Voor deze casus hebben we de geschatte standaardfout (SE_{diff}) nodig van het verschil tussen twee steekproefgemiddelden.
- Die geschatte standaardfout hangt af van de spreiding binnen beide groepen en van de steekproefgroottes.
- Als de spreiding in beide populaties vergelijkbaar is, vatten we die samen met de gepoolde standaarddeviatie s_p.
- Met s_p kunnen we vervolgens de geschatte standaardfout van het verschil berekenen.

Met s_p schatten we vervolgens SE_{diff}

$$SE_{\text{diff}} = s_p\sqrt{\frac{1}{n_I} + \frac{1}{n_C}} = 9,76\sqrt{\frac{1}{40} + \frac{1}{40}} = 2,18$$

Gepoolde standaarddeviatie

Steekproefgegevens	$n_I = 40$, $n_C = 40$, $s_I = 9,7$, $s_C = 9,8$
Formule	$s_p = \sqrt{\frac{(n_I - 1)s_I^2 + (n_C - 1)s_C^2}{n_I + n_C - 2}}$
Invullen	$s_p = \sqrt{\frac{(40 - 1) \cdot 9,7^2 + (40 - 1) \cdot 9,8^2}{40 + 40 - 2}}$
Resultaat	**$s_p = 9,76$**

95%-BI voor het gemiddeld verschil

- Nu we SE_{diff} hebben geschat, kunnen we een 95%-BI opstellen voor het gemiddeld verschil.
- De opbouw is hetzelfde als in college 1: schatting ± kritieke waarde × geschatte standaardfout.
- De kritieke t-waarde lezen we af uit een t-verdeling met $df = n_I + n_C - 2$ vrijheidsgraden.

df is niet de kritieke waarde zelf. De vrijheidsgraden bepalen welke t-verdeling je gebruikt; uit die verdeling lees je vervolgens de kritieke waarde af.

Berekening van het 95%-BI

Gegeven	$\bar{x}_I - \bar{x}_C = -3{,}8$, $SE_{diff} = 2{,}18$
Geschatte SE	$SE_{diff} = 2{,}18$
df	$df = n_I + n_C - 2 = 78$
Kritieke t-waarde	$t_{(0{,}975;df)} = 1{,}99$
Formule	$(\bar{x}_I - \bar{x}_C) \pm t_{(0{,}975;df)} \times SE_{diff}$
Invullen	$-3{,}8 \pm 1{,}99 \times 2{,}18 = [-8{,}2;\ 0{,}5]$

Van schatten naar toetsen

- Tot nu toe stond schatten centraal: hoe groot is het gemiddeld verschil in BBS% tussen beide groepen?
- Daarbij gebruikten we een puntschatting en een 95%-BI.
- We kunnen dezelfde casus ook formuleren als een toetsingsvraag: geven deze data aanwijzingen dat de interventie invloed heeft op het gemiddelde BBS%?
- Voor die vraag gebruiken we de onafhankelijke t-toets.

Onafhankelijke t-toets: toets voor het vergelijken van een continue uitkomst tussen twee onafhankelijke groepen, onder de aanname van gelijke varianties.

Casus 1: BBS% bij recallpatiënten

H_0 (nulhypothese)
Het gemiddelde BBS% is gelijk in beide groepen: $\mu_I = \mu_C$.

H_1 (alternatieve hypothese)
Het gemiddelde BBS% verschilt tussen de groepen: $\mu_I \neq \mu_C$.

Onafhankelijke t-toets: toetsgrootheid onder H_0

- Het geschatte gemiddeld verschil is $\bar{x}_I - \bar{x}_C = -3{,}8$ pp.
- De toetsingsgrootheid $t = (\bar{x}_I - \bar{x}_C) / SE_{diff}$ drukt dit geschatte verschil uit in eenheden van geschatte standaardfouten.
- Intuïtief passen t-waarden dicht bij 0 beter bij H_0 dan t-waarden die verder van 0 liggen.
- Onder H_0 vergelijken we deze t-waarde met een t-verdeling met $df = n_I + n_C - 2 = 78$, om te bepalen hoe extreem deze uitkomst is als er in de populatie geen verschil is.

Berekening van t voor de casus:
t = -3,8 / 2,18 = -1,76

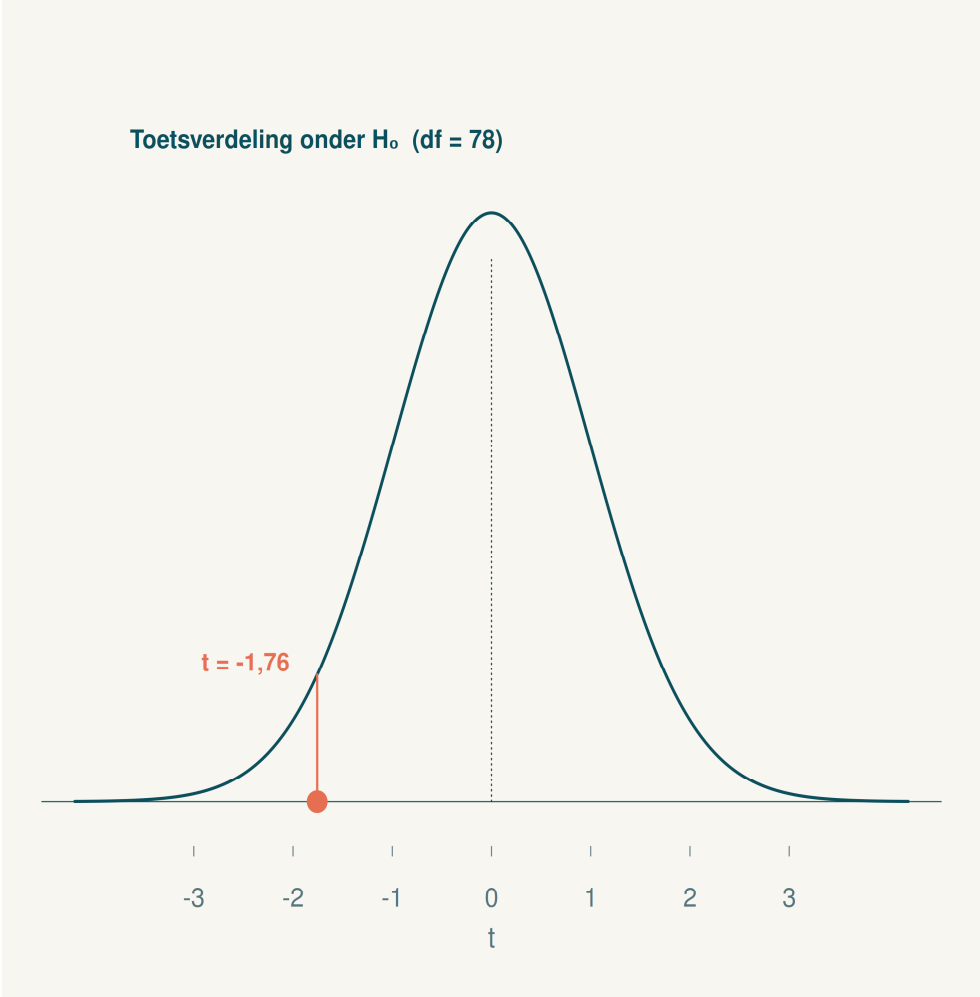

P-waarde en conclusie

- Voor deze casus vinden we t(78) = -1,76 en p = 0,083.
- De p-waarde vat samen hoe extreem deze uitkomst is als H_0 waar is.
- Hoe kleiner de p-waarde, hoe minder goed de uitkomst past bij H_0.
- Omdat p > 0,05 verwerpen we H_0 niet.
- Er is dus geen statistisch significant verschil in gemiddeld BBS% tussen de groepen.

Rapportage: "De gemiddelde BBS% verschilde niet significant tussen de groepen: t(78) = -1,76, p = 0,083."

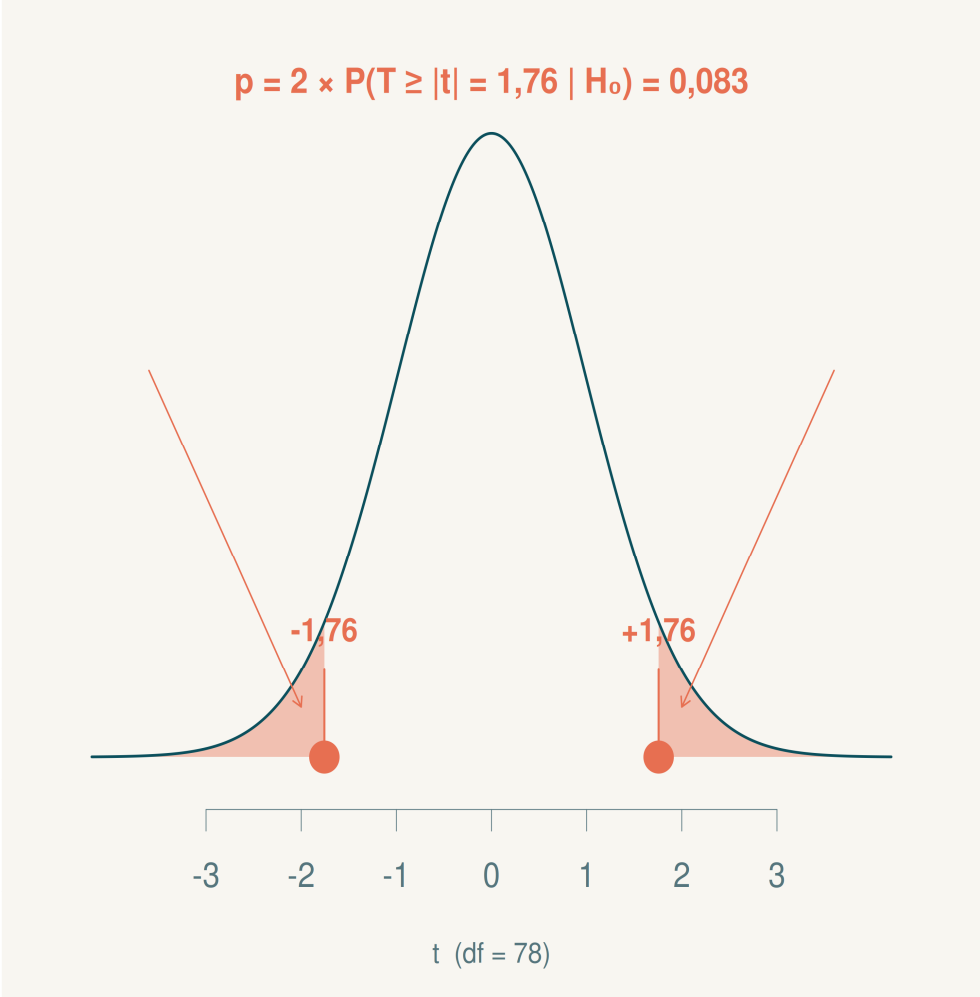

Aanname 1: normaliteit (visuele controle)

- Een eerste aanname van de klassieke onafhankelijke t-toets is dat de uitkomst in beide groepen normaal verdeeld is.
- Dat beoordelen we met een histogram per groep.
- We letten daarbij op sterke scheefheid, uitbijters of meerdere toppen.
- In deze casus lijken beide verdelingen redelijk symmetrisch, dus de aanname van normaliteit is aanvaardbaar.

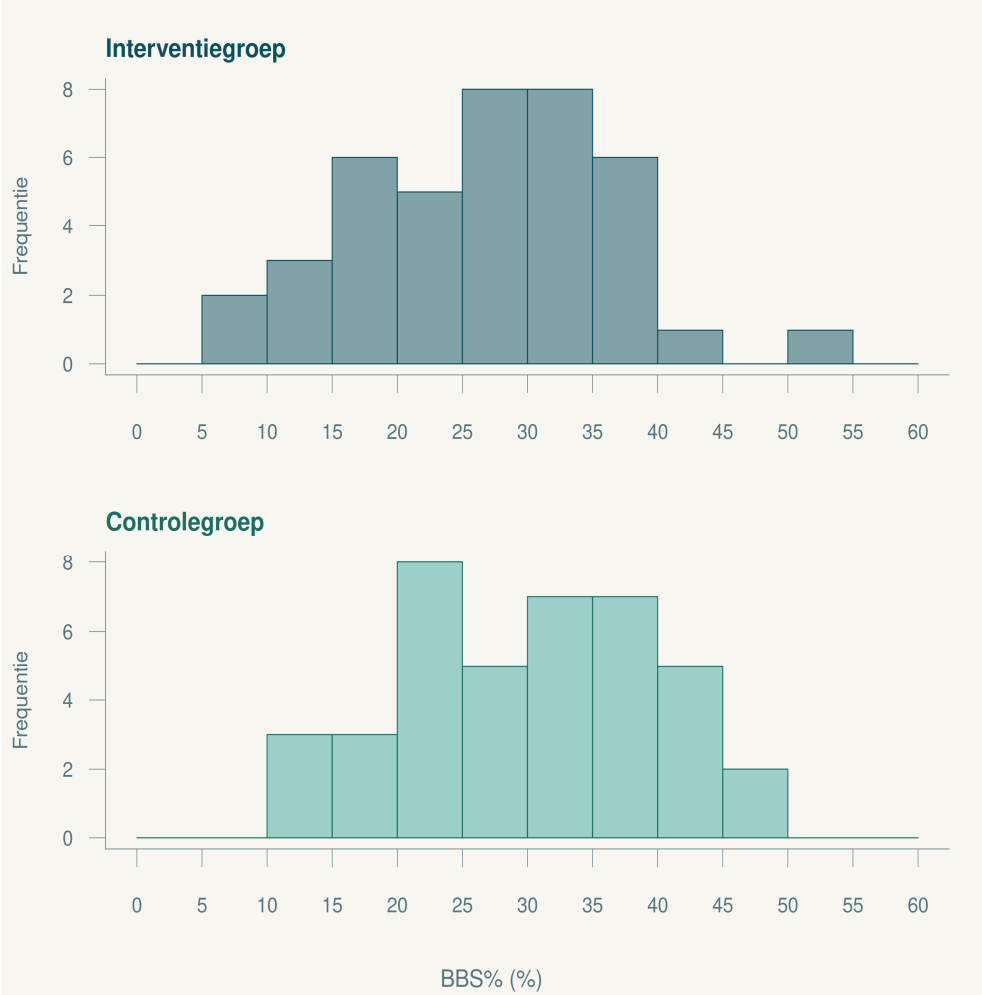

Aanname 2: gelijke varianties (Levene's test)

- Een tweede aanname van de klassieke onafhankelijke t-toets is dat de spreiding in beide groepen vergelijkbaar is.
- Levene's test helpt ons beoordelen of die aanname redelijk is.
- H_0: de varianties zijn gelijk in beide groepen.
- In ons voorbeeld: $F(1, 78) = 0{,}17$, $p = 0{,}677$; de aanname van gelijke varianties is aanvaardbaar.

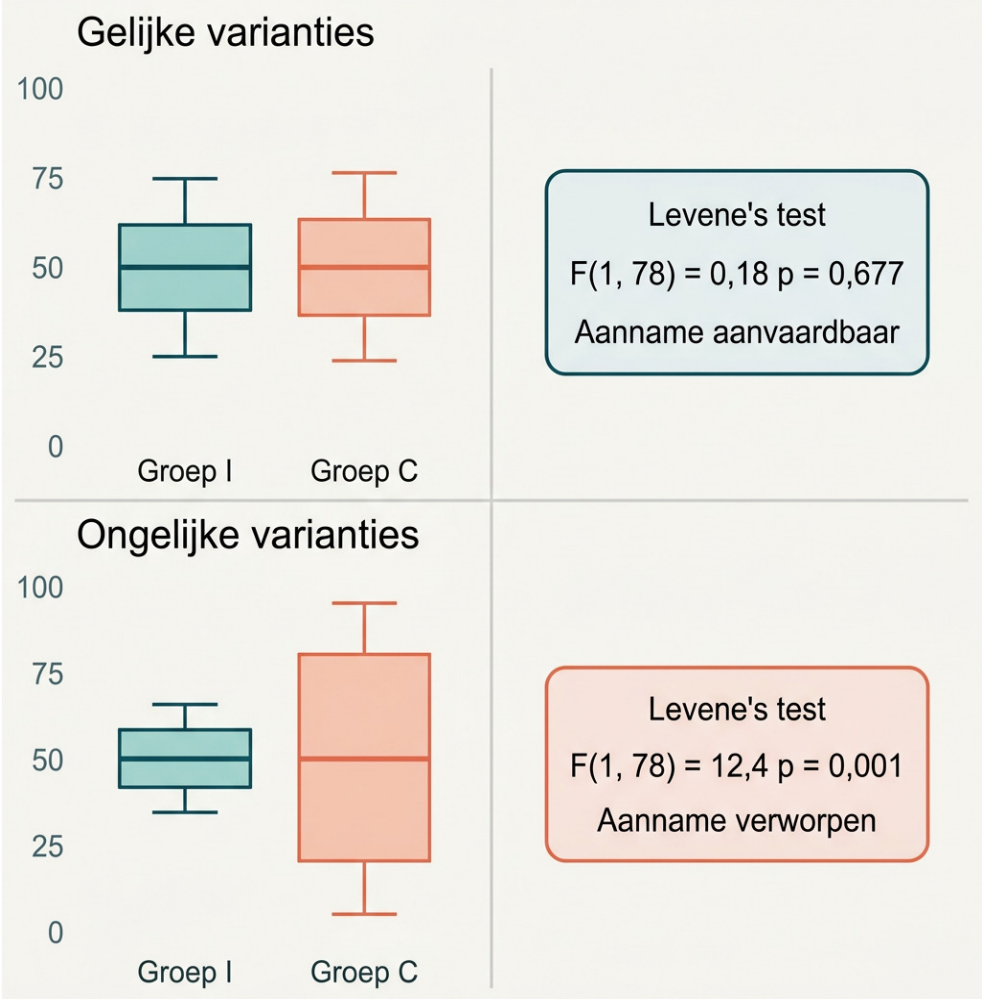

Quizvraag: welke studie heeft de grootste gepoolde SD?

Opzet Beide studies hebben dezelfde steekproefgrootte.

95%-BI's op dezelfde schaal

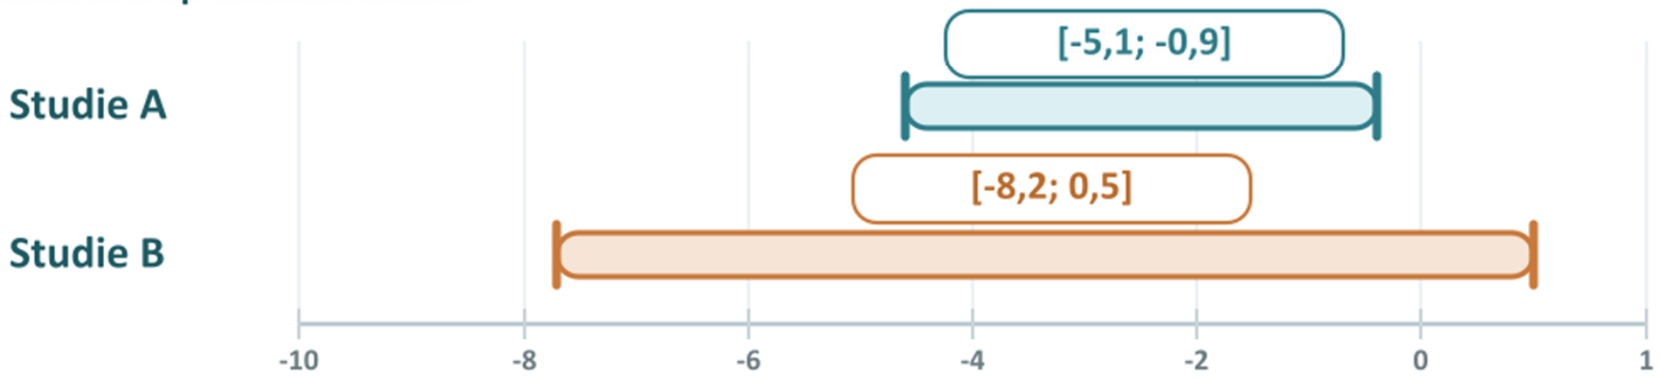

A) Studie A

B) Studie B

C) beide even groot

Quizvraag: welke studie heeft de hoogste p-waarde?

In beide studies gaat het om een tweezijdige t-toets.

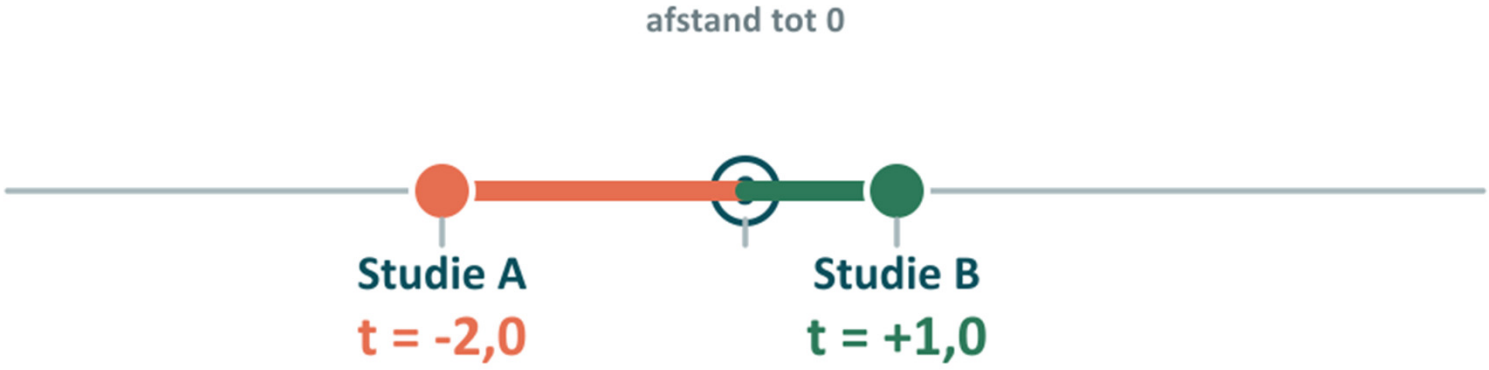

A) Studie A

B) Studie B

C) beide even hoog

Deel 2

Als aannames wankelen: welke toets dan?

Beslisboom: welke toets kies je?

- We vergelijken twee onafhankelijke groepen op een continue uitkomst.
- Vraag 1: is de uitkomst ongeveer normaal verdeeld?
  - Nee of twijfelachtig: kies Mann-Whitney U toets.
  - Ja: kijk vervolgens of de varianties vergelijkbaar zijn.
    - Varianties niet vergelijkbaar: kies Welch's t-toets.
    - Varianties vergelijkbaar: kies de klassieke t-toets.

De BBS%-casus uit Deel 1 kwam uit bij de klassieke onafhankelijke t-toets; nu bekijken we twee casussen die naar andere takken van de beslisboom leiden.

Casus 2: pocketdieptereductie in twee groepen

- Populatie: patiënten met parodontale pockets die een niet-chirurgische behandeling ondergaan.
- Interventie: SRP + adjunctieve behandeling (n = 32).
- Controle: alleen SRP (n = 32).
- Uitkomst: gemiddelde pocketdieptereductie na behandeling.
- Vraag: in hoeverre verschilt de gemiddelde pocketdieptereductie tussen de interventiegroep en de controlegroep?

SRP = scaling and root planing: een niet-chirurgische parodontale behandeling waarbij tandsteen en plaque onder het tandvlees worden verwijderd en worteloppervlakken worden gladgemaakt.

Beschrijvende statistiek: pocketdieptereductie

- We starten met beschrijvende statistiek en een visuele verkenning van de data per groep.
- De uitkomst lijkt per groep redelijk normaal verdeeld.
- De spreiding lijkt echter niet goed vergelijkbaar tussen de twee groepen.
- Dat is een aanwijzing dat de klassieke onafhankelijke t-toets minder geschikt kan zijn.

Levene's test: $F(1, 62) = 12{,}07$, $p = 0{,}001$. De varianties lijken niet goed vergelijkbaar tussen de groepen.

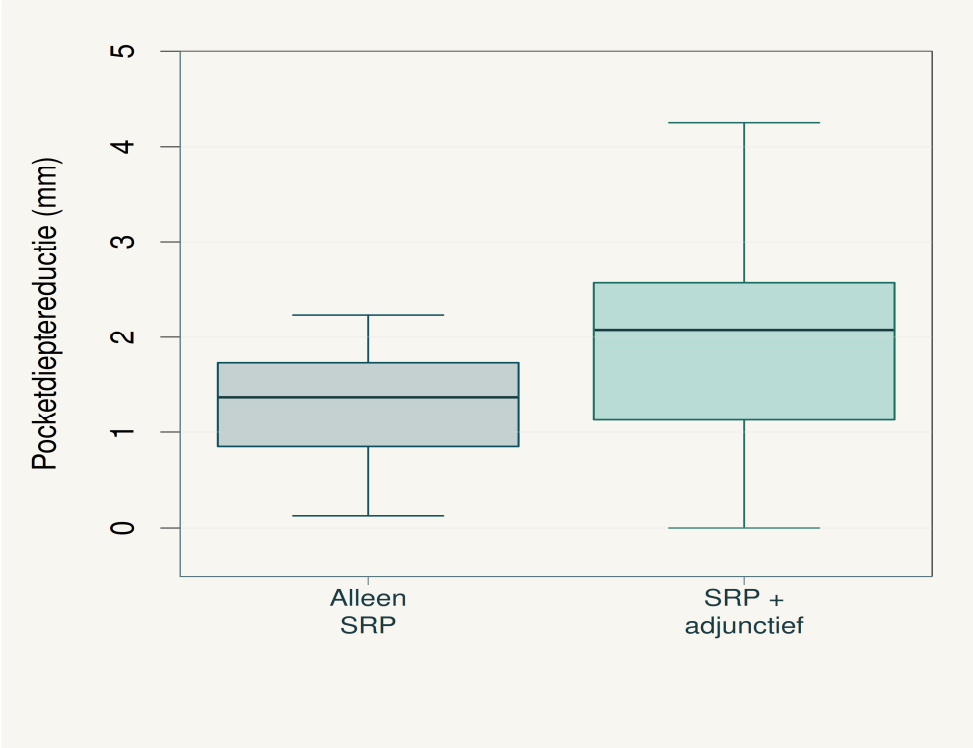

Steekproefsamenvatting

Groep	Gem.	SD
Alleen SRP	1,25 mm	0,55 mm
SRP + adjunctief	1,87 mm	1,12 mm

Resultaten: Welch's t-toets

- In de vorige slide zagen we dat de spreiding in beide groepen niet goed vergelijkbaar is.
- Daarom gebruiken we hier niet de klassieke onafhankelijke t-toets, maar Welch's t-toets.
- Ook met Welch's t-toets toetsen we of de gemiddelde pocketdieptereductie verschilt tussen beide groepen.
- Het verschil zit in de manier waarop de standaardfout en de vrijheidsgraden worden bepaald.

Bij Welch's t-toets worden de standaardfout en de vrijheidsgraden aangepast aan de groepsgroottes en varianties. De precieze formules hoef je niet uit het hoofd te kennen; het is vooral belangrijk dat je software-output correct kunt lezen.

Resultaten casus 2

Verschil	1,87 - 1,25 = 0,62 mm
t	2,81 (0,62 / geschatte SE)
df	45,05
p-value	0,007
Conclusie	**Er is een statistisch significant verschil in gemiddelde pocketdieptereductie.**

SPSS-output: welke regel en welke p-waarde?

Independent Samples Test

		Levene's Test for Equality of Variances		t-test for Equality of Means							
						Significance		Mean Difference	Std. Error Difference	95% Confidence Interval of the Difference	
		F	Sig.	t	df	One-Sided p	Two-Sided p			Lower	Upper
pocketdiepteredactie_mm	Equal variances assumed	12,070	<,001	2,809	62	,003	,007	,6216	,2213	,1793	1,0639
	Equal variances not assumed			2,809	45,049	,004	,007	,6216	,2213	,1760	1,0673

Gebruik Levene's test eerst om te bepalen welke regel je moet aflezen, en lees daarna in die regel de tweezijdige p-waarde af.

Als Levene niet significant is

- gebruik de regel *Equal variances assumed*
- lees daar de tweezijdige p-waarde af

Als Levene wel significant is

- gebruik de regel *Equal variances not assumed*
- lees daar de tweezijdige p-waarde af

Omdat de groepsgroottes hier gelijk zijn, is de standaardfout in beide regels hetzelfde. Als de groepsgroottes verschillen, kunnen ook de standaardfouten verschillen en wordt het onderscheid tussen beide regels belangrijker.

Casus 3: uren tot pijnvrij na extractie

- Populatie: patiënten na extractie.
- Interventie: standaard nazorg + gestructureerde telefonische begeleiding over pijnmedicatie en mondverzorging (n = 35).
- Controle: standaard nazorg (n = 35).
- Uitkomst: aantal uren tot pijnvrij.
- Vraag: in hoeverre verschilt de tijd tot pijnvrij tussen de interventiegroep en de controlegroep?

Beschrijvende statistiek: uren tot pijnvrij

- We starten opnieuw met beschrijvende statistiek en een visuele verkenning van de data per groep.
- De verdeling van het aantal uren tot pijnvrij lijkt scheef.
- Daardoor is een vergelijking van gemiddelden minder geschikt.
- Dat is een aanwijzing om een niet-parametrische toets te overwegen.

Opmerking: bij scheve verdelingen is de mediaan vaak informatiever dan het gemiddelde.

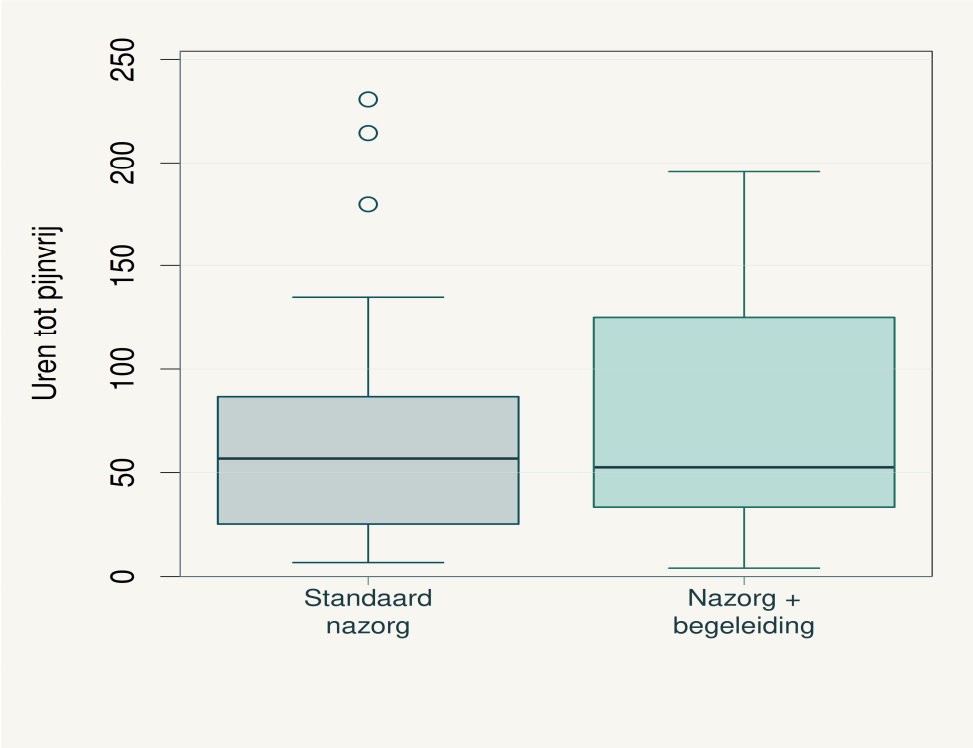

Steekproefsamenvatting

Groep	Mediaan	IQR
Standaard nazorg	56,6 u	[25,0; 86,7]
Nazorg + begeleiding	52,5 u	[33,0; 125,2]

Mann-Whitney U toets

- De Mann-Whitney U toets is een niet-parametrische toets voor twee onafhankelijke groepen.
- Niet-parametrisch betekent hier dat we minder sterke verdelingsaannamen maken dan bij de klassieke t-toets.
- De hypothesen gaan bij deze toets niet over een verschil in populatiegemiddelden, maar over de verdelingen van de uitkomst in beide groepen.
- Als die verdelingen vooral in ligging verschillen, kan dit vaak worden gelezen als een verschil in mediaan.

Hypothesen

H_0: de verdelingen in beide groepen zijn gelijk

H_1: de verdelingen verschillen tussen beide groepen

Liggingverschil als interpretatie

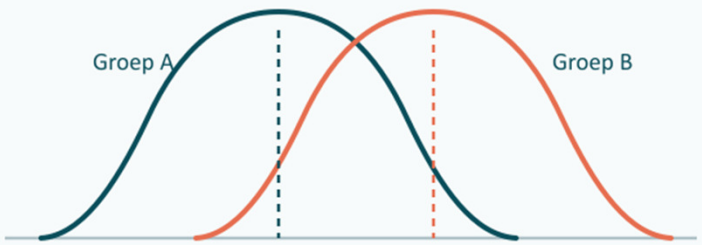

Als de verdelingen vooral in ligging verschillen,
kan dat vaak worden gelezen als een verschil in mediaan.

Van waarnemingen naar rangnummers

- We nemen alle waarnemingen uit beide groepen samen en ordenen die van laag naar hoog.
- Vervolgens kennen we rangnummers toe aan deze geordende waarden.
  - Bij gelijke waarden krijgen die waarnemingen het gemiddelde van de rangnummers die zij samen innemen.
- Ten slotte berekenen we voor beide groepen de som van de toegekende rangnummers.

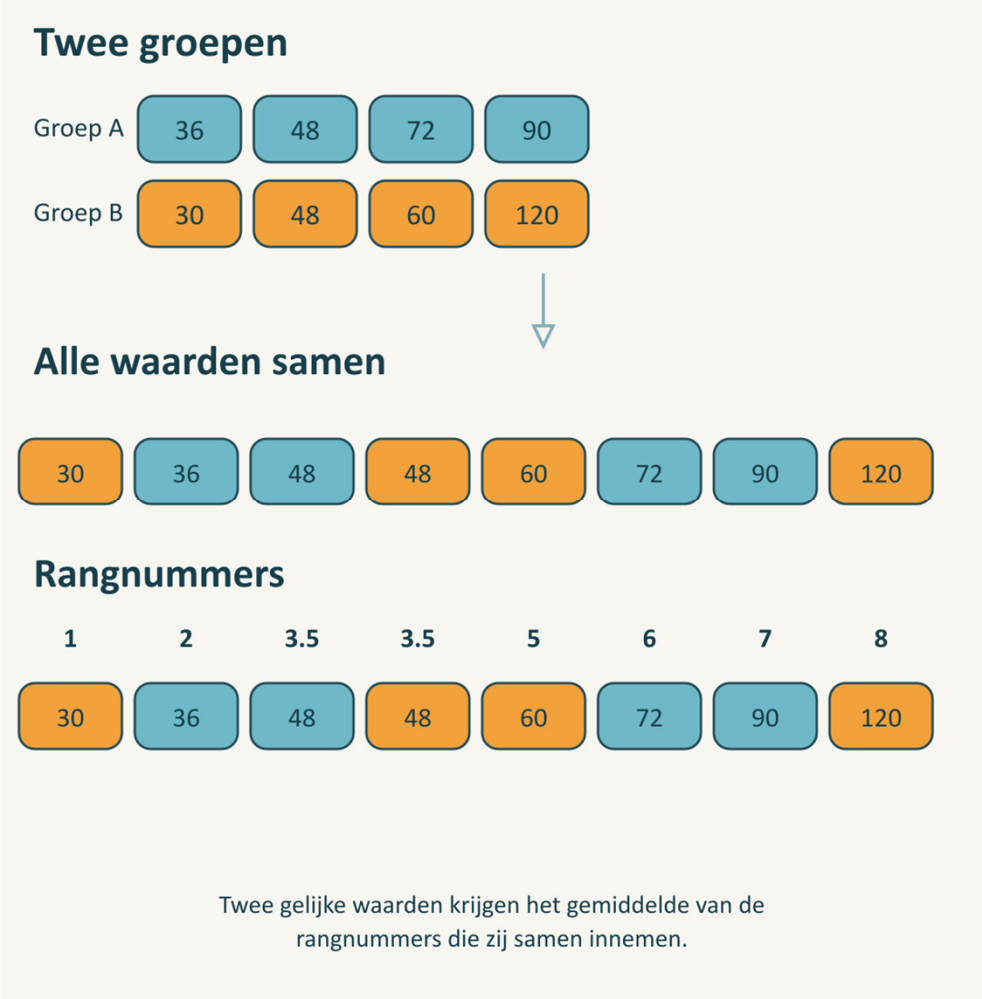

Van rangsommen naar toetsuitkomst

- We bepalen eerst de som van de rangnummers van één groep; dit is de rank-sum statistiek W.
- Op basis van W berekenen we de Mann-Whitney U-statistiek.
- Software rapporteert vervolgens vaak W, U, een gestandaardiseerde Z-waarde en de bijbehorende p-waarde.
- Zo toetsen we of de geobserveerde rangverdeling past bij H_0 of juist wijst op een verschil tussen de groepen.

Rapportage: “De verdeling van uren tot pijnvrij verschilde niet significant tussen de groepen (Mann-Whitney U = 657,0, p = 0,601).”

Ranginformatie per groep

Groep	n	Som rangen	Gem. rang
Standaard nazorg	35	1198,0	34,23
Nazorg + begeleiding	35	1287,0	36,77

Van W naar U

W = 1287,0

U = W - n(n + 1)/2

U = 1287,0 - 35(35 + 1)/2 = 657,0

P-waarde en conclusie

Z = 0,52

p = 0,601

Geen statistisch significant verschil tussen de groepen.

Einde

Vragen?